



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА «Системы обработки информации и управления»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

Исследование задач оптимизации запасов на основе ма-
шинного обучения

Студент ИУ5И-33М
(Группа)

(Подпись, дата) Люй Чжэ
(И.О.Фамилия)

Руководитель

(Подпись, дата) Ю.Е. Гапанюк
(И.О.Фамилия)

2024 г

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ

Заведующий кафедрой ИУ-5
(Индекс)
В. И. Терехов
(И.О.Фамилия)
« ____ » _____ 2024 г.

З А Д А Н И Е

на выполнение научно-исследовательской работы

по теме Исследование задач оптимизации запасов на основе машинного обучения

Студент группы ИУ5И-33М

Люй Чжэ

(Фамилия, имя, отчество)

Направленность НИР (учебная, исследовательская, практическая, производственная, др.)

исследовательская

Источник тематики (кафедра, предприятие, НИР) КАФЕДРА

График выполнения НИР: 25% к ____ нед., 50% к ____ нед., 75% к ____ нед., 100% к ____ нед.

Техническое задание Исследование различных методов машинного обучения, связанных с 3 задачами оптимизации запасов

Оформление научно-исследовательской работы:

Расчетно-пояснительная записка на 22 листах формата А4.

Перечень графического (иллюстративного) материала (чертежи, плакаты, слайды и т.п.)

Дата выдачи задания « 04 » сентября 2024 г.

Руководитель НИР

(Подпись,

дата

Ю.Е. Гапанюк

И.О.Фамилия)

Студент

(Подпись,

дата

Люй Чжэ

И.О.Фамилия)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре.

Оглавление

Введение	4
1. Актуальность и значимость исследования	5
2. Концепции, связанные с оптимизацией запасов	6
2.1 Определение и вызовы оптимизации запасов	6
2.2 Прогнозирование спроса в цепочке поставок и создание страхового запаса	7
2.3Общепринятые стратегии инвентаризации	11
3. Теории машинного обучения	13
3.1 Алгоритм случайного леса	14
3.2 Алгоритм нейронной сети ВР	16
3.3 Теория имитационного моделирования	18
4. Заключение	20
5. Список литератур	22

Введение

Оптимизация запасов играет ключевую роль в современном управлении цепочками поставок, решая задачи, связанные с неопределенностью спроса, минимизацией затрат и эффективным распределением ресурсов. В данной работе исследуется применение методов машинного обучения для повышения точности прогнозирования спроса и определения уровня страховых запасов, что способствует снижению издержек и повышению операционной эффективности.

Исследование начинается с обзора основных понятий оптимизации запасов, включая прогнозирование спроса, установление страховых запасов и распространенные стратегии управления запасами. Далее рассматриваются теоретические аспекты машинного обучения с акцентом на алгоритмы случайного леса и нейронных сетей прямого распространения (ВР), которые показали высокую эффективность в задачах управления цепочками поставок. Также вводятся методы имитационного моделирования для динамической оценки и совершенствования стратегий управления запасами.

Результаты исследования применяются к реальным сценариям, демонстрируя, как модели машинного обучения могут эффективно прогнозировать спрос и оптимизировать уровень запасов в различных условиях. Полученные данные подтверждают преимущества интеграции машинного обучения и имитационного моделирования, предоставляя практические рекомендации для улучшения управления запасами.

Данное исследование предлагает ценные рекомендации для специалистов, стремящихся использовать передовые аналитические методы для оптимизации запасов, и служит основой для дальнейших исследований в этой области.

1. Актуальность и значимость исследования

В условиях глобализации и высокой конкурентоспособности современного рынка управление запасами становится одной из ключевых задач в цепочках поставок. Эффективная оптимизация запасов позволяет минимизировать издержки, поддерживать высокий уровень удовлетворённости клиентов и снижать влияние неопределённости спроса. Однако традиционные методы управления запасами зачастую сталкиваются с ограничениями при обработке большого объёма данных и учёте сложных факторов, таких как колебания спроса, сезонные тренды и внешние рыночные условия.

Методы машинного обучения предлагают новые возможности для решения этих проблем, позволяя анализировать большие объёмы данных, прогнозировать спрос с высокой точностью и оптимизировать уровень запасов. Их применение становится всё более актуальным для предприятий, стремящихся повысить эффективность управления ресурсами. Настоящее исследование посвящено изучению методов машинного обучения в области оптимизации запасов, что имеет важное практическое и научное значение.

Целью данного исследования является изучение применения методов машинного обучения для оптимизации управления запасами. В работе рассматриваются основные подходы к прогнозированию спроса и определению уровней страховых запасов с использованием машинного обучения.

Методология исследования включает:

- ✧ анализ теоретических основ оптимизации запасов и машинного обучения;
- ✧ разработку моделей на основе методов случайного леса и ВР-нейронных сетей;
- ✧ проведение вычислительных экспериментов с использованием языка программирования Python;
- ✧ оценку эффективности предложенных подходов.

Работа состоит из трёх глав:

- ✧ В первой главе обоснована актуальность темы, определены цели исследования, а также кратко описан используемый подход.
- ✧ Во второй главе изложены теоретические основы оптимизации запасов и машинного обучения, включая основные методы и стратегии.
- ✧ В третьей главе представлены результаты исследования и даны рекомендации по улучшению управления запасами на основе машинного обучения.

2. Концепции, связанные с оптимизацией запасов

2.1 Определение и вызовы оптимизации запасов

Оптимизация запасов включает различные мероприятия по контролю запасов, направленные на минимизацию затрат, поддержание производства, стабилизацию запасов и снижение потерь. В любой организации важно поддерживать разумный уровень запасов. Чрезмерные запасы занимают слишком много места на складах, увеличивают затраты на их хранение и сокращают оборотные средства, что сказывается на повседневной деятельности предприятия. С другой стороны, недостаток запасов приводит к высоким затратам, так как перебои в поставках из-за нехватки запасов могут снижать удовлетворенность и доверие клиентов, что в свою очередь приводит к потере заказов. Эффективное управление запасами позволяет удовлетворить потребности клиентов при минимальных затратах на поддержание запасов. Говоря простыми словами, оптимизация запасов заключается в заказе нужных материалов в нужное время и поддержании разумного уровня запасов.

Сложности оптимизации запасов связаны с неопределенностью в цепочке поставок. Источники неопределенности различны:

С точки зрения поставщиков: задержки в поставке сырья, транспортные риски и другие факторы.

С точки зрения производителей: непредвиденные перебои в производстве, недостаточная производственная мощность для удовлетворения спроса.

С точки зрения потребителей: колебания цен, психологические факторы, социальные тенденции и другие аспекты, влияющие на предпочтения покупателей и, соответственно, на спрос.

Эти неопределенности проявляются в спросе в цепочке поставок. Спрос связывает все звенья цепи поставок, при этом верхние звенья работают, чтобы удовлетворить спрос нижних. Если спрос стабилен или полностью известен, предприятия могут принимать обоснованные решения для оптимизации запасов. Однако такая идеальная ситуация редко встречается. Узлы цепочки поставок не могут предсказать будущий спрос, а также не имеют полной информации о реальном спросе других звеньев цепочки. Когда информация о спросе передается через звенья цепочки, колебания спроса усиливаются, что вызывает эффект "кну́та". Этот эффект создает следующие основные проблемы:

- (1) Значительные колебания спроса вынуждают предприятия увеличивать запасы для обеспечения бесперебойных поставок.
- (2) Производственные планы предприятий приходится постоянно корректировать в ответ на изменения спроса, что вызывает дополнительные затраты.

(3) Неопределенность спроса может привести к разрыву партнерских отношений в цепочке поставок.

Эти проблемы увеличивают сложность оптимизации запасов и могут привести к краху всей цепочки поставок. Неопределенность спроса и поставок подчеркивает необходимость поддержания запасов в определенных местах для обеспечения необходимого уровня обслуживания.

Все усилия предприятий по оптимизации запасов направлены на то, чтобы справиться с неопределенностью спроса, снизить эффект "кну́та" и, таким образом, уменьшить затраты на запасы. Многие исследователи и практики цепочки поставок разработали различные методы оптимизации запасов для работы с неопределенностью спроса, среди которых наиболее распространенными являются определение уровня страхового запаса и прогнозирование спроса.

2.2 Прогнозирование спроса в цепочке поставок и создание страхового запаса

В последние несколько десятилетий в связи с тенденцией глобализации и аутсорсинга многие компании стали сотрудничать с хорошими поставщиками по всему миру, что привело к значительному увеличению сроков производства и поиска товаров. По мере увеличения времени ожидания точность прогнозирования спроса, как правило, снижается, поэтому для компаний становится крайне важным точно прогнозировать спрос.

Все аспекты цепочки поставок, закупки, производство и транспортировка, основаны на прогнозах, и точные методы прогнозирования спроса могут смягчить эффект «бычьей волны» и повысить эффективность цепочки поставок, а повышение точности краткосрочных прогнозов также является одним из способов построения более гибких цепочек поставок для производственных компаний [1].

Традиционно существует два основных подхода к прогнозированию спроса: качественный и количественный. Со временем количество соответствующих исследований увеличилось, и эти методы были расширены до нескольких типов, а также появилось несколько других идей и комбинаций методов прогнозирования. К распространенным методам качественного прогнозирования относятся метод Дельфи, метод опроса, метод прогнозирования на основе суждений менеджеров и т. д. Методы качественного прогнозирования подходят для прогнозирования некоторых временных рядов, для которых не хватает исторических данных и которые в значительной степени зависят от способности профессионалов проникать в рынок. Благодаря простоте и удобству он по-прежнему является первым выбором при прогнозировании многих товаров с относительно фиксированным

спросом или новых продуктов, по которым отсутствуют исторические данные. В большинстве случаев компании используют комбинацию качественных и количественных прогнозов. Качественное прогнозирование закладывает основу для количественного прогнозирования, определяет основные тенденции развития и повышает точность количественного прогнозирования. Количественные методы прогнозирования можно разделить на методы прогнозирования временных рядов, основанные на статистических методах и алгоритмах машинного обучения. Традиционный метод прогнозирования временных рядов может быть адаптирован только к небольшому количеству факторов, влияющих на спрос на прогнозирование, таких как тренд, сезонность, цикличность и так далее. С одной стороны, их применение зависит от характеристик самих данных, и методы, применимые к одним данным, могут не дать точных прогнозов по другим, а с другой - эти методы требуют специальных статистических знаний, и бизнес-персонал не может ими владеть. Методы машинного обучения - это алгоритмы распознавания образов на основе данных, которые не накладывают строгих предположений на процесс генерирования данных, поэтому они более применимы и могут учитывать более широкий спектр влияющих факторов, достигая лучших результатов прогнозирования во многих задачах [2]. С развитием междисциплинарного пересечения граница между этими двумя направлениями становится все более размытой. Распространенные методы прогнозирования приведены в таблице 1 ниже.

Классификация методов	Название метода	Характеристики и применимость
Качественный метод прогнозирования	Метод экспертного прогнозирования	Легко понять, легко управлять, но прогноз субъективен, а точность невысока. Подходит для прогнозирования новых продуктов, для которых не хватает исторических данных.
	Метод Дельфи	
	Метод маркетинговых исследований	
	Регрессионный анализ	Адаптация нескольких влияний для составления прогнозов, таких как тенденции, сезонность, цикличность и т. д., требует высокой степени гладкости данных.
	Скользящее среднее	
	Метод серого прогнозирования	

Количественный метод прогнозирования	Алгоритм Random Forest	Точность прогнозирования высока и позволяет учесть множество факторов, однако он плохо поддается интерпретации, требует большого количества исторических данных для обучения и требует больших вычислительных затрат.
	Алгоритм нейронной сети BP	
	Алгоритм нейронной сети BP	
	Алгоритм PROPHET	
	Алгоритм LSTM	

Таблица 1. Введение в методологию прогнозирования

В управлении запасами в цепочке поставок запас прочности обычно рассматривается как дополнительный запас, создаваемый для решения проблемы неопределенности спроса и предложения с целью предотвращения дефицита запасов. Поскольку тенденция глобализации и аутсорсинга привела к увеличению времени выполнения заказа и повлияла на точность прогнозов спроса, стало крайне важно иметь разумный запас прочности, чтобы сбалансировать ошибки прогнозов. Что касается рыночного спроса, то предпочтения потребителей в отношении любого продукта могут меняться с течением времени все чаще, и такие изменения могут привести к значительным отклонениям от моделей, наблюдавшихся в прошлом. Необходимость для компаний создавать разумные резервные запасы для широкого спектра продуктов, чтобы достичь цели удовлетворения рыночного спроса и снижения затрат на ведение бизнеса, представляет собой вызов для области управления запасами.

На создание резервных запасов влияет множество факторов, включая уровни обслуживания, сроки поставки, волатильность спроса, стратегии заказа и стоимость хранения [3]. Разумный запас прочности должен не только учитывать непрерывность производства фирмы, но и удовлетворять требованиям клиента к заказу и в то же время минимизировать стоимость запасов.

Традиционно при планировании запасов необходимый запас устанавливается на соответствующем уровне путем оценки колебаний спроса в течение времени ожидания, а затем на основе заранее определенного уровня обслуживания потребителя (далее CSL), который можно интерпретировать как способность удовлетворить спрос потребителя в течение определенного периода обслуживания и который может быть использован для оценки

эффективности цепи поставок. эффективности цепочки поставок. Обычно он выражается в процентах, например, CSL за год может быть выражен следующим уравнением (2.1):

$$CSL = 1 - \frac{\text{Количество недополученных грузов в год}}{\text{Количество заказов в год}} \quad (2.1)$$

CSL устанавливается не как можно выше, в зависимости от таких факторов, как собственная структура затрат на запасы в узле цепи поставок, и должен быть соответствующим образом снижен, когда стоимость удовлетворения спроса клиентов значительно превышает стоимость усилий компании по его удовлетворению. Уровень безопасного запаса обычно рассчитывается в предположении (1) фиксированной ошибки в прогнозировании спроса и (2) фиксированного времени на пополнение запасов. Иногда используются более сложные методы, позволяющие динамически обновлять значения запасов по мере изменения условий. Исходя из природы нормального распределения, после определения CSL можно определить соответствующий коэффициент безопасности запасов Z . Таблица, соответствующая CSL и Z , приведена в таблице 2 ниже:

CSL	Z
50.00	0
75.00	0.67
80.00	0.84
85.00	1.04
90.00	1.29
95.00	1.65
99.00	2.33
100.00	3.09

Таблица 2. Таблица соответствия между CSL и коэффициентом безопасности

Если спрос имеет нормальное распределение $N(\mu, \delta^2)$, то спрос за время опережения L также имеет нормальное распределение, поэтому среднее значение D_L и стандартное отклонение δ_L спроса за время опережения даны в уравнениях (2.2) и (2.3) ниже:

$$D_L = \sum_{i=1}^L D_i = L\mu \quad (2.2)$$

$$\delta_L = \sqrt{\sum_{i=1}^L \delta^2} = \sqrt{L}\delta \quad (2.3)$$

Запасы безопасности и целевые запасы, основанные на требованиях к времени выполнения заказа, выражены в уравнениях (2.4) и (2.5) ниже:

$$SS = z\delta_L = z\delta\sqrt{L} \quad (2.4)$$

$$S = D_L + SS = L\mu + z\delta\sqrt{L} \quad (2.5)$$

В реальной производственной деятельности спрос на продукцию может меняться в зависимости от жизненного цикла товара, климата и других факторов, а спрос на некоторые товары не подчиняется нормальному распределению. Его можно рассчитать на основе алгоритма создания резервного запаса, разработанного Американским обществом по контролю за производством и запасами (APICS). Компаниям необходимо регистрировать и анализировать исторические данные о спросе, делать точные прогнозы будущего спроса и рассчитывать запас прочности с учетом ошибок прогноза и уровня обслуживания клиентов. Метод состоит из следующих этапов:

- (1) Запишите последовательность исторических продаж товаров в период i : P_i и последовательность прогнозов продаж товаров Q_i :

$$P_i = (p_1, p_2, \dots, p_{i-1}) \quad (2.6)$$

$$Q_i = (q_1, q_2, \dots, q_{i-1}) \quad (2.7)$$

- (2) Величина ошибки предсказания может быть представлена в виде:

$$\Delta_i^2 = (P_i - Q_i)^2 = \sum_{j=1}^{i-1} (p_j - q_j)^2 \quad (2.8)$$

- (3) Тогда значение стандартного отклонения прогноза может быть выражено как:

$$\sigma_i = \sqrt{\frac{\Delta_i^2}{n-1}} \quad (2.9)$$

- (4) Запас прочности SS_i фирмы может быть выражен как:

$$SS_i = z\sigma_i\sqrt{L} \quad (2.10)$$

Тогда целевые запасы можно выразить как:

$$S = \widehat{D}_L + SS \quad (2.11)$$

$$S = z\widehat{\sigma}_L \quad (2.12)$$

где \widehat{D}_L обозначает прогноз фирмы на время опережения, а $\widehat{\sigma}_L$ - стандартное отклонение ошибки прогноза спроса.

2.3 Общепринятые стратегии инвентаризации

(1) Модель контроля запасов с непрерывной проверкой. Эта модель требует, чтобы фирма осуществляла мониторинг запасов в режиме реального времени и пополняла запасы всякий раз, когда уровень запасов становится меньше заданной точки заказа R . Модель контроля запасов основана на стратегии непрерывного контроля запасов. Общими стратегиями непрерывного контроля запасов являются стратегии (R, Q) и (R, S) . Стратегия (R, Q) рассчитывает необходимый запас прочности на основе времени ожидания, а затем определяет партию заказа Q , которая остается постоянной. Стратегия (R, S) пополняет запасы до максимального уровня запасов S , поэтому партия заказа равна максимальному уровню запасов S минус текущий уровень запасов.

(2) Модель управления запасами с периодической проверкой. При этой стратегии фирма проверяет уровень запасов в каждый промежуток времени t и определяет количество заказов на каждый период. В зависимости от объема пополнения запасов она может быть разделена на стратегию (t,S) и стратегию (t,R,S) . (Стратегия (t,S) пополняет запасы каждый второй период до максимального уровня запасов S . Стратегия (t,R,S) определяет точку заказа R поверх стратегии (t,S) , где заказ происходит только тогда, когда уровень запасов меньше R , снова пополняя запасы до уровня S .

Сходства и различия между различными стратегиями управления запасами представлены в таблице 3 ниже:

Стратегия управления запасами	(R,Q)	(R,S)	(t,S)	(t,R,S)
Инспекционный цикл	непрерывная проверка	непрерывная проверка	Периодическая проверка	Периодическая проверка
Пункт выдачи заказов	R	R	Не фиксировано	R
Время заказа	Запасы ниже R	Запасы ниже R	t	Запасы в момент времени t достигают R
Количество заказа	Q	Дополнение к S	Дополнение к S	Дополнение к S

Таблица 3. Стратегия управления запасами

3. Теории машинного обучения

Искусственный интеллект - это область знаний, посвященная разработке компьютеров, способных имитировать человеческий интеллект и поведение, а машинное обучение - важная область исследований в ИИ. Машинное обучение включает в себя изучение интеллекта и обучение алгоритмов для получения знаний на основе опыта. Задача машинного обучения - обнаружить в данных соответствующие структурные и временные закономерности, называемые «знаниями», которые часто скрыты в произвольно больших пространствах и не могут быть извлечены человеком для получения достоверной информации. В зависимости от типа данных, которые алгоритмическая модель получает в процессе обучения, машинное обучение можно разделить на: (1) контролируемое обучение (2) неконтролируемое обучение (3) полуконтролируемое обучение (4) обучение с подкреплением. Для контролируемого обучения требуется набор обучающих данных, включающий входные примеры, а также выходные маркированные ответы или целевые значения. Входные и выходные данные из обучающего набора используются для настройки параметров модели. После того как модель успешно обучена, ее можно использовать в заданной ситуации с новыми данными для прогнозирования целевой переменной Y . Неподконтрольное обучение происходит, когда модель обучается без каких-либо предварительных меток или заданных значений в наборе данных. Обучающие данные состоят только из признаков X , и цель состоит в том, чтобы найти в них структурную информацию. В качестве примера можно привести классификацию данных, содержащих общие атрибуты, в один класс (так называемая кластеризация) или проецирование данных из пространства высокой размерности в пространство низкой размерности (так называемое снижение размерности). Если данные содержат как маркированную, так и немаркированную информацию, это называется полуподконтрольным обучением. В системе обучения с подкреплением вместо предоставления пар входных и выходных данных описывается текущее состояние системы или задается цель, предоставляется список допустимых действий и ограничений окружающей среды на их результат, и модель получает опыт достижения цели по принципу метода проб и ошибок для максимизации вознаграждения.[4]

Многие ученые исследовали контролируемое обучение, и оно получило наиболее широкое применение в реальной жизни. Данная статья посвящена применению алгоритмов классификации и регрессии в контролируемом обучении в области цепочек поставок. Если заданная метка данных Y является непрерывной величиной, процесс обучения с использованием X для

предсказания Y называется регрессией. Если метка данных Y имеет дискретный тип, ее можно отнести к задаче классификации.

3.1 Алгоритм случайного леса

✧ Основные принципы алгоритма

Алгоритм случайного леса широко используется благодаря своей высокой гибкости и объяснимости. Он применяется как для задач классификации, таких как прогноз оттока клиентов, классификация запасов, оценка кредитного риска, так и для задач регрессии, например, для прогнозирования объема спроса, цен на продукцию или будущих объемов производства.

Как следует из названия, случайный лес состоит из двух ключевых компонентов: "случайность" и "лес". Лес формируется из множества деревьев, а каждое дерево в случайном лесу — это дерево решений. Случайность же означает, что процесс построения деревьев включает в себя элементы случайности.

Дерево решений является базовым элементом случайного леса. Оно структурировано как дерево: начальная точка — это корневой узел, из которого происходят ветвления. Каждое ветвление представляет собой критерий разделения данных, а конечные узлы (листья) содержат окончательные результаты. Цель состоит в том, чтобы максимизировать "чистоту" каждого узла, т.е. чтобы в каждом конечном узле находились объекты одной категории.

В основе алгоритма случайного леса, реализованного в библиотеке `scikit-learn` для Python, лежит усовершенствованное дерево решений CART. Это дерево выбирает признаки для разделения на основе индекса Джини, который рассчитывается по формуле (3.1):

$$\text{Gini}(D) = 1 - \sum_{k=1}^{|C|} p_k^2 \quad (3.1)$$

где p_k — вероятность принадлежности объекта классу k , а $|C|$ — количество классов.[5]

Процесс построения случайного леса состоит из следующих шагов:

- Случайный выбор подмножества объектов из общего тренировочного набора методом "выборки с возвращением".
- Для каждого подмножества объектов случайный выбор признаков для построения дерева.
- Построение дерева решений для каждого подмножества.
- Прогнозирование с использованием всех деревьев: для задачи регрессии — усреднение результатов, для задачи классификации — выбор класса, который встречается чаще всего (мода).

Хорошие или плохие результаты прогнозирования модели машинного обучения зависят не только от собранных данных, но и от настроек ключевых параметров модели. В данной работе для прогнозирования заданы следующие ключевые параметры, остальные могут быть установлены в значения по умолчанию. Количество деревьев: чем больше этот параметр, тем больше деревьев решений генерируется в модели, что может улучшить эффективность обобщения модели, но в то же время увеличивает объем вычислений. Максимальная глубина: максимальная глубина, на которой каждое дерево решений расщепляется и растет; установка этого параметра позволяет предотвратить возникновение явления избыточной подгонки.

✧ Важность признаков в модели дерева

В реальной производственной и операционной деятельности множество факторов могут влиять на результаты прогнозов. Для оптимизации и сокращения затрат руководители, как правило, уделяют первоочередное внимание факторам, которые оказывают наибольшее влияние на результаты прогнозов. Кроме того, слишком большое количество признаков не только увеличивает вычислительную сложность модели, но и может ухудшить её производительность. Поэтому выявление важности каждого признака имеет большое практическое значение.

Оценка важности признаков осуществляется путём анализа вклада каждого признака в работу алгоритма. У случайного леса есть естественное преимущество: в процессе его построения для каждой решающей модели (дерева решений) выбирается только часть данных, а не выбранные данные могут использоваться как новые данные для проверки модели. Эти данные называются "внепакетными" (out-of-bag, OOB). Ошибки на данных OOB могут служить показателем для оценки модели. Кроме того, для оценки важности признаков можно использовать индекс Джини.

✧ Визуализация модели дерева

Одной из самых заметных особенностей дерева решений является его интерпретируемость. Процесс обучения дерева решений эквивалентен созданию набора правил классификации, которые затем используются для разделения данных. Эти правила можно извлечь и визуализировать. На рисунке 2-8 представлена типичная визуализация дерева решений: каждый прямоугольный блок представляет узел дерева. Верхний узел — это корневой узел, содержащий все образцы, участвующие в построении данного дерева решений. Каждый узел предоставляет правила разделения, используемые для последовательного деления образцов, а также включает индекс Джини, информацию о классификации образцов и другие данные.

Использование методов визуализации для анализа процесса построения дерева решений помогает руководителям глубже понять принципы работы алгоритма прогнозирования, что способствует применению алгоритмов машинного обучения в практической деятельности предприятий.

✧ Преимущества и недостатки алгоритма

При использовании алгоритмов важно полностью понимать их преимущества и ограничения. Слепой выбор алгоритма часто приводит к неудовлетворительным результатам и значительно увеличивает время обучения.

Алгоритм случайного леса подходит как для задач классификации, так и для задач регрессии. Он может обрабатывать как категориальные, так и числовые переменные без необходимости стандартизации данных, что делает его предпочтительным выбором для множества задач. Случайный лес является универсальным инструментом в области машинного обучения и часто используется как базовая модель для сравнения с другими алгоритмами. Благодаря особенностям процесса обучения случайный лес может обрабатывать пропущенные значения и не требует выполнения предварительного выбора признаков. Наличие внепакетных данных (OOB) позволяет реализовать процесс кросс-валидации и упрощает проверку модели, а также позволяет оценить важность каждого признака.

Однако случайный лес имеет и свои недостатки. При работе с большими наборами данных обучение каждой решающей модели требует значительных вычислительных ресурсов, что становится препятствием для его выбора. Кроме того, при решении задач регрессии дерево решений не может выдавать непрерывные значения, а вместо этого использует усреднение. Это ограничивает возможность делать прогнозы за пределами диапазона обучающих данных, что может приводить к переобучению на шумных наборах данных.

3.2 Алгоритм нейронной сети ВР

ВР (Back Propagation, обратное распространение ошибки) — это один из самых популярных и широко используемых алгоритмов обучения многослойных нейронных сетей. ВР-нейронная сеть состоит из трёх основных слоёв: входного, скрытого и выходного. Каждый слой содержит определённое количество нейронов, которые соединены между собой весами. Алгоритм ВР основывается на двух ключевых процессах: прямом распространении и обратном распространении ошибки.

Прямое распространение: на входной слой подаётся входной сигнал, который затем последовательно передаётся через скрытые слои в выходной слой. Каждый нейрон в сети вычисляет взвешенную сумму входов, добавляет

смещение и применяет функцию активации, например, сигмоидальную или ReLU. Формула для расчёта выхода нейрона:

$$y = f(\sum_{i=1}^n w_i x_i + b) \quad (3.2)$$

где y — выход нейрона, x_i — входные сигналы, w_i — веса, b — смещение, f — функция активации.

Обратное распространение ошибки: на основе разницы между прогнозируемым и истинным значением рассчитывается ошибка. Затем ошибка распространяется назад по сети, чтобы корректировать веса на каждом уровне. Для обновления весов используется метод градиентного спуска, описываемый формулой:

$$w_i^{(t+1)} = w_i^t - \eta \frac{\partial E}{\partial w_i} \quad (3.3)$$

где w_i^t — вес на текущей итерации, η — коэффициент обучения, E — ошибка сети.

Процесс обучения ВР-нейронной сети можно разделить на следующие этапы:

- Инициализация весов и смещений случайными значениями.
- Прямое распространение входного сигнала, получение выходных значений.
- Вычисление ошибки сети:

$$E = \frac{1}{2} \sum_{i=1}^n (y_i - t_i)^2 \quad (3.4)$$

где y_i — прогнозируемое значение, t_i — истинное значение.

- Обратное распространение ошибки: вычисление градиента и обновление весов.
- Повторение шагов 2–4 до достижения заданного уровня точности или истечения максимального количества итераций.

ВР-нейронная сеть реализует преобразование входных данных в выходные и подходит ко всем нелинейным непрерывным функциям с произвольной точностью при увеличении числа скрытых слоев. Это связано с ее мощной способностью к самообучению, которая может помочь в решении задач со сложными внутренними механизмами. Однако с увеличением сложности задачи объем данных и вычислений, требуемых нейронной сетью, также резко возрастает, и во многих случаях время, потраченное на это, не приводит к значительному улучшению. Нейронные сети также широко критикуются за их «черный ящик», когда люди не могут понять их внутренние механизмы и поэтому не используют результаты их вычислений.

Эффект предсказания нейронной сети ВР зависит от ее внутренней структуры, но полной теории о том, как выбрать структуру, не существует, и обычно она строится на основе опыта.

3.3 Теория имитационного моделирования

Использование математических моделей для описания и решения реальных систем является распространенным методом решения систем. Для задачи оптимизации запасов многие ученые разработали метод математической модели для решения этой задачи, принимая минимизацию стоимости запасов в качестве целевой функции и различные ограничения в качестве ограничений, решая модель для определения оптимальной точки заказа и количества заказа. В условиях острой конкуренции на рынке и возросшей неопределенности, с которой сталкивается цепочка поставок внутри и снаружи, трудно использовать математические модели для описания сложной и динамичной системы запасов. Развитие компьютерных технологий значительно улучшило вычислительные мощности, с помощью компьютерного программного обеспечения можно помочь людям моделировать для достижения всех видов сложных моделей в реальности и решать их. Системное моделирование использует статистику, системное моделирование, кибернетику и другие дисциплины в качестве своей теоретической основы, и его преимущество заключается в том, что количественный анализ может быть легко осуществлен и результаты моделирования могут быть выведены, так что для получения информации, необходимой для принятия решений.

Существует множество способов классификации имитационных моделей, например, непрерывные и дискретные: в непрерывной системе состояние системы изменяется непрерывно с течением времени, а в дискретной системе изменение состояния системы происходит только в определенные моменты времени; детерминированные и стохастические: модель без случайных переменных является детерминированной, а в стохастической модели присутствуют хотя бы некоторые случайные входные данные. Процессно-ориентированные и объектно-ориентированные: процессно-ориентированные имитационные модели сосредоточены на событиях системы, которые приводятся в действие путем определения серии постепенно наступающих событий. В объектно-ориентированной имитационной модели различные объекты системы идентифицируются путем определения атрибутов и поведения, разделения проблемы по функциям и достижения имитационного моделирования системы посредством взаимодействия объектов. В настоящее время на рынке существует множество популярных программ для моделирования, таких как Vensim, Flexsim, Anylogic и т.д., также их можно программировать с помощью компьютерных языков, таких как Python, Java и т.д., различные методы моделирования и программное обеспечение имеют различные сценарии применения.

Общий подход к проведению имитационных исследований можно свести к следующим этапам:

(1) Определите цель имитационного моделирования. Прежде всего, необходимо выяснить, может ли решаемая проблема быть использована в методе, после уточнения метода использования имитационного моделирования, тщательно продумать цели создания имитационной системы, и определить, какими должны быть выходные данные модели.

Создайте имитационную модель, исходя из поставленных целей.

(2) Создание концептуальной модели. Реальная система сложна и изменчива, и система имитации не может полностью описать реальную систему, при создании имитационной модели необходимо уловить основные противоречия, выделив саму проблему, которую необходимо решить. Концептуальная модель может быть создана сначала путем создания блок-схемы, чтобы понять различные шаги в создании имитационной системы.

(3) Сбор данных. Цель имитационного исследования определяет, какие данные необходимо собрать, объем и тип данных, входные данные могут быть собраны не только через реальность исследования, но и через опыт оценок и расчетов.

(4) Имитационное моделирование. Концептуальная модель программируется с помощью компьютерного программного обеспечения для абстрагирования проблемы в имитационную систему, состоящую из элементов моделирования, математических или логических выражений, случайных распределений вероятности, процессов моделирования и правил для описания природы реальной системы.

(5) Валидация модели. Внимательно изучите, может ли имитационная модель соответствовать реальной системе, нет ли в ней противоречий с эмпирическим здравым смыслом, можно попробовать запустить программу или проверить код, чтобы подтвердить правильность модели.

(6) Вывод и анализ результатов моделирования. Установив правила работы модели, прогоните результаты моделирования много раз, чтобы убедиться в достоверности результатов, в сочетании с реальной ситуацией выводимых результатов моделирования для дальнейшего анализа и сравнения, вы можете использовать математическую статистику для проверки результатов, рисовать графики и диаграммы для визуализации результатов, чтобы получить более интуитивное понимание.

4. Заключение

В рамках данного исследования были подробно рассмотрены ключевые аспекты управления цепочкой поставок и использования алгоритмов машинного обучения для оптимизации процессов. Основное внимание было уделено следующим направлениям:

Анализ теоретических основ управления запасами, прогнозирования спроса и моделирования процессов. Было выявлено, что современные методы управления цепочкой поставок должны учитывать неопределенность спроса и временных параметров, а также необходимость минимизации издержек.

Исследование алгоритмов машинного обучения, включая случайный лес и ВР-нейронные сети, для задач прогнозирования и принятия решений. Было показано, что каждый алгоритм имеет свои преимущества и ограничения, и выбор подходящего метода зависит от конкретной задачи.

Использование симуляционного моделирования для анализа и оптимизации процессов в цепочке поставок. Было выявлено, что симуляция позволяет более глубоко понять поведение сложных систем и предложить решения, учитывающие множество факторов.

Результаты настоящей работы имеют как теоретическое, так и практическое значение:

Теоретическая значимость:

Данное исследование расширяет понимание применения современных методов машинного обучения и моделирования в управлении цепочкой поставок.

Были уточнены подходы к оценке важности признаков и прогнозированию спроса.

Практическая значимость:

Предложенные методы могут быть использованы предприятиями для повышения эффективности управления запасами и улучшения уровня обслуживания.

Симуляционные модели, предложенные в работе, могут быть адаптированы для анализа конкретных производственных процессов.

На основе выполненного анализа были определены направления для дальнейших исследований:

- Разработка интегрированных моделей, объединяющих машинное обучение и симуляцию, для более точного прогнозирования и управления в условиях неопределенности.
- Изучение применения других алгоритмов машинного обучения, таких как глубокое обучение и методы ансамблирования, для решения задач в цепочке поставок.

- Проведение эмпирических исследований на основе данных реальных предприятий для проверки и улучшения предложенных моделей.

5. Список литературы

- [1] Rego J R D, Mesquita M A D. Demand forecasting and inventory control: A simulation study on automotive spare parts[J]. International Journal of Production Economics, 2015, 161:1-16.
- [2] Andreas H. Introduction to machine learning & knowledge extraction[J]. Machine Learning & Knowledge Extraction, 2017, 1(1): 1-20.
- [3] Perspectives O. Operations research models and methods for safety stock determination: A review[J]. Operations Research Perspectives, 2020, 7: 124-136.
- [4] Jordan M I, Mitchell T M. Machine learning: Trends, perspectives, and prospects[J]. Science, 2015, 349(6245): 255-260.
- [5] Islam S, Amin S H. Prediction of probable backorder scenarios in the supply chain using Distributed Random Forest and Gradient Boosting Machine learning techniques[J]. Journal of Big Data, 2020, 7(1): 1-22.
- [6] Huber Jakob, Müller Sebastian, Fleischmann Moritz. A data-driven newsvendor problem: From data to decision[J]. European Journal of Operational Research, 2019, 278(3): 904-915.
- [7] Kilimci Z H, Akyuz A O, Uysal M, et al. An Improved Demand Forecasting Model Using Deep Learning Approach and Proposed Decision Integration Strategy for Supply Chain[J]. Complexity, 2019, 2019: 1-15.
- [8] Zhong Miaowang. Construction of an Electronic Recycling System and Price Determination under Multi-Agent Behavior in Reverse Supply Chains [D]. Liaoning University of Science and Technology, 2019.